Análisis metodológico del desarrollo de modelos de pronóstico

Evaluación de SARIMA, SARIMAX, CNN-1D y TCN para el pronóstico mensual de ventas de supermercados

Archivos revisados: ajuste_y_comparacion_modelos_ML-21-oct-26.ipynb e Input_series.xlsx.

Fecha del informe: 21 de octubre de 2026.

Alcance: auditoría del diseño experimental, tratamiento de series, estrategia de estimación, validación, métricas reportadas y recomendaciones de mejora.

Nota de alcance: las métricas consignadas corresponden a salidas almacenadas en el notebook y no constituyen una nueva ejecución verificada con la planilla adjunta.

1. Resumen ejecutivo

El estudio compara cuatro enfoques de pronóstico: SARIMA, SARIMAX, una red convolucional unidimensional (CNN-1D) y una red convolucional temporal (TCN). La variable de interés es vsup (ventas de supermercados) y se utilizan indicadores económicos complementarios para explorar mejoras de precisión. El desarrollo configura ventanas de 24 meses y un horizonte de predicción de un mes.

El código combina construcción de muestras, estimación de modelos, normalización para redes neuronales y evaluación con una ventana expansiva. El enfoque es conceptualmente pertinente, especialmente por respetar el orden cronológico. No obstante, las limitaciones del diseño experimental aconsejan tratar las conclusiones actuales como exploratorias.

Hallazgo principal: SARIMAX presenta los menores errores en la ejecución guardada, pero la comparación está condicionada por un conjunto pequeño de muestras, estrategias de estimación no equivalentes, ausencia de validación interna y una discrepancia entre el archivo de datos disponible y los resultados almacenados.

Fortalezas identificadas

- Orientación clara a un pronóstico mensual a un paso.
- Comparación de arquitecturas econométricas y de aprendizaje profundo.
- Separación cronológica de entrenamiento y evaluación.
- Normalización de datos ajustada dentro de cada partición para las redes neuronales.
- Empleo de MAE, RMSE y MAPE como medidas complementarias de precisión.

Limitaciones prioritarias

- Falta de reproducibilidad inmediata entre la planilla recibida y las salidas guardadas.
- Filtrado de observaciones por variables que luego se excluyen del entrenamiento.
- Solamente 36 muestras supervisadas y 12 muestras iniciales de entrenamiento.
- SARIMA/SARIMAX estimados con series históricas de 24/23 observaciones.
- Ausencia de validación interna independiente y early stopping basado en error de entrenamiento.
- Disponibilidad de publicación de las variables exógenas no auditada.

2. Caracterización metodológica del problema

2.1. Propósito predictivo

Se busca estimar el valor mensual futuro de ventas de supermercados, a partir de su propia trayectoria y de series de actividad económica y comercial. La formulación básica es:

$$\hat{y}(t+1) = f\,[\, y(t), \ldots, y(t-23), X(t), \ldots, X(t-23) \,]$$

Aquí y representa ventas de supermercados; X representa el conjunto de indicadores adicionales y f la función de predicción. Las redes neuronales utilizan las secuencias de entrada; SARIMA emplea la variable objetivo y SARIMAX incorpora predictores externos rezagados.

Debe diferenciarse un objetivo predictivo (minimizar el error fuera de muestra) de uno explicativo (identificar relaciones e interpretar coeficientes). Una mejor precisión multivariada no demuestra causalidad.

2.2. Rasgos de las series económicas

Las series pueden contener tendencia, estacionalidad mensual, cambios estructurales, distintas escalas, colinealidad y diferentes fechas de inicio. Ello justifica analizar estacionariedad, rezagos, transformaciones, estabilidad temporal y disponibilidad real de los datos antes de adoptar una especificación definitiva.

3. Auditoría de la base de datos

3.1. Variables

Código	Descripción	Uso
vsup	Ventas de supermercados	Objetivo
vasmay	Ventas de autoservicios mayoristas	Excluida del entrenamiento final
vcc	Ventas de centros de compras	Explicativa
velec	Ventas de electrodomésticos y artículos del hogar	Explicativa
vmcame	Índice de ventas minoristas CAME	Explicativa
argiva	Recaudación del IVA	Explicativa
ica_arg	Índice compuesto de actividad económica	Explicativa
bc_arg	Indicador binario de expansión/recesión	Explicativa

La combinación final utiliza siete variables: la dependiente y seis explicativas. La exclusión de vasmay aparece fijada en la selección de columnas y no acompañada de un análisis sistemático de sensibilidad.

3.2. Cobertura y restricciones de disponibilidad

El identificador de períodos de la planilla se extiende desde enero de 1996 hasta diciembre de 2026; esto no implica que todas las columnas tengan observaciones efectivas en todo el rango.

Serie	Primer período observado
vsup	Enero de 1996
vasmay	Enero de 2017
vcc	Enero de 1997
velec	Enero de 2001
vmcame	Julio de 2012
argiva	Enero de 1996
ica_arg	Enero de 1996
bc_arg	Enero de 1996

El constructor de muestras examina valores faltantes de las ocho columnas originales, incluida vasmay, aun cuando esta última luego no interviene en el entrenamiento. Esto puede descartar observaciones utilizables y restringir artificialmente la historia de los modelos.

Recomendación: generar las muestras para cada subconjunto efectivo de variables, y no exigir observaciones de series excluidas. Comparar configuraciones con menos predictores y más historia.

3.3. Escalas, formatos y fechas

La planilla reúne valores monetarios, índices y una variable binaria. Para las redes se aplica StandardScaler calculado con los datos de entrenamiento de cada partición, evitando el ajuste con la observación que se evalúa. Es conveniente contrastar niveles con tasas de crecimiento o transformaciones logarítmicas cuando corresponda.

Los períodos codificados numéricamente (por ejemplo, 2025.09) deben convertirse a fechas mensuales explícitas para garantizar un ordenamiento, detección de huecos y cálculo de rezagos inequívocos.

3.4. Reproducibilidad de los datos

En la planilla adjunta hay celdas #N/A en períodos recientes y filas de 2026 con faltantes. En cambio, las salidas conservadas en el notebook contienen ventanas de entrenamiento que alcanzan marzo de 2026. La versión de Input_series.xlsx recibida no permite asumir que se reproducen las métricas guardadas.

No puede determinarse la causa exacta solo con estos archivos. Antes de publicar resultados, se debe documentar la versión de la base, fecha de corte, transformaciones, hash del archivo, librerías y semilla de aleatoriedad.

4. Construcción de muestras supervisadas

4.1. Longitud y horizonte

WINDOW_SIZE = 24 define secuencias de 24 meses; target_idx = end_idx + 1 fija la variable objetivo en el mes posterior a la ventana. La formulación es adecuada para un horizonte de un paso, pero la ventana de 24 meses fue preestablecida sin comparar alternativas.

Se propone contrastar 12, 24, 36 y 48 meses mediante validación temporal interna. La ventana debe elegirse por desempeño fuera de muestra y disponibilidad de observaciones, no solo por conveniencia computacional.

4.2. Submuestreo aleatorio

RANDOM_STEPS = [2, 3] y RANDOM_SEED = 20 determinan saltos aleatorios de dos o tres meses. Este mecanismo reduce el número de ventanas, pero también elimina información y deja evaluaciones no necesariamente consecutivas. Dos ventanas separadas por dos meses comparten 22 de 24 observaciones, por lo que la dependencia sigue siendo alta.

Una única semilla hace reproducible la selección, pero no demuestra robustez de las conclusiones ante muestras alternativas. Se recomienda partir de todas las ventanas mensuales consecutivas y, solo después, evaluar submuestreo como experimento independiente.

4.3. Muestras efectivas

Indicador	Valor almacenado
Ventana	24 meses
Variables originales	8
Variables de entrenamiento	7
Muestras generadas	36
Muestras descartadas	258
Muestras iniciales de entrenamiento	12
Particiones de evaluación	24

$$X \in R^{(36 \times 24 \times 7)}$$

36 secuencias supervisadas no equivalen a un conjunto grande de ejemplos independientes: las ventanas comparten numerosos períodos. Esta limitación es central para interpretar el entrenamiento y el riesgo de sobreajuste de las redes neuronales.

5. Evaluación de las especificaciones

5.1. SARIMA

Se emplea SARIMA(1,1,1)(0,1,1) con período estacional 12. La elección es plausible para series económicas mensuales, pero no se documenta una selección formal con ACF/PACF, pruebas de estacionariedad, AIC/BIC, comparación de órdenes ni diagnóstico de residuos.

En cada evaluación el ajuste utiliza únicamente los 24 valores de la ventana objetivo. Tras diferenciación regular y estacional, la información efectiva es especialmente escasa. Conviene estimar también una versión con toda la historia de la variable dependiente disponible hasta cada origen.

5.2. SARIMAX

El modelo SARIMAX(1,1,1)(0,1,1) con estacionalidad 12 incorpora seis variables explicativas rezagadas. El rezago pretende evitar exigir el valor futuro de X, una decisión conceptualmente correcta, aunque debe contrastarse con las fechas reales de publicación.

La especificación utiliza aproximadamente 23 observaciones alineadas para estimar simultáneamente dinámica temporal, estructura estacional y coeficientes de las variables exógenas. Esto puede generar estimaciones inestables y problemas de multicolinealidad. Se aconseja probar historia expansiva, selección de variables, regularización o restricciones parsimoniosas y rezagos específicos.

5.3. CNN-1D

Característica	Configuración
Canales	8
Kernel	3
Dropout	0,30
Parámetros entrenables	257

La CNN-1D identifica patrones temporales locales y relaciones potencialmente no lineales. Su arquitectura relativamente compacta es adecuada como ensayo inicial, pero 257 parámetros siguen siendo muchos respecto de 12 muestras iniciales de entrenamiento. La capacidad de generalización debe evaluarse con particiones independientes y distintas inicializaciones.

5.4. TCN

Característica	Configuración
Canales	8 y 8
Kernel	2
Dropout	0,30
Parámetros entrenables	601

La TCN puede capturar dependencias temporales mediante convoluciones especializadas. Sus 601 parámetros amplían flexibilidad y riesgo de ajuste excesivo con pocas secuencias. Resulta apropiada como modelo experimental, pero requiere pruebas de estabilidad, regularización y disponibilidad de más ejemplos efectivos.

6. Entrenamiento y normalización

6.1. Escalado

$$Z = (X - \mu_{entrenamiento}) / \sigma_{entrenamiento}$$

La media y desviación estándar se estiman en cada conjunto de entrenamiento y las predicciones se retornan luego a la escala original. El procedimiento evita una fuga directa desde el conjunto evaluado. Aun así, la superposición de ventanas puede sobreponderar algunos períodos al calcular las estadísticas.

6.2. Parámetros de entrenamiento de las redes

Parámetro	Configuración
Épocas máximas	250
Tamaño de lote	4
Tasa de aprendizaje	0,001
Weight decay	0,001
Paciencia	35
Optimizador	AdamW
Pérdida	MSE

La configuración es razonable como punto de partida. El problema más importante es que el criterio para guardar la mejor época compara train_loss con best_loss: el early stopping se basa en el error de entrenamiento y no en una validación independiente. Por tanto, no detecta directamente la pérdida de generalización.

Corrección recomendada: reservar una fracción cronológicamente posterior del entrenamiento como validación interna en cada partición, evaluar allí el error y utilizarlo para guardar el mejor modelo y detener el ajuste. La observación externa final no debe intervenir en esa selección.

7. Evaluación temporal y comparabilidad

7.1. Esquema expansivo

La rutina denominada temporal_leave_one_out_comparison ordena cronológicamente las muestras y utiliza un conjunto expansivo: inicialmente muestras 1–12 para estimar y muestra 13 para probar; luego 1–13 para estimar y 14 para probar, hasta evaluar la muestra 36. Son 24 pronósticos externos individuales.

Partición	Entrenamiento	Prueba
1	Muestras 1–12	Muestra 13
2	Muestras 1–13	Muestra 14
3	Muestras 1–14	Muestra 15
24	Muestras 1–35	Muestra 36

Esta validación respeta cronología y evita entrenar con objetivos correspondientes a períodos posteriores a la prueba. Es mejor describirla como ventana expansiva con evaluación de un ejemplo por partición que como leave-one-out convencional.

7.2. Asimetría de estimación

Las CNN y TCN utilizan todas las secuencias de entrenamiento previas a la prueba. SARIMA, en cambio, se estima solamente con la ventana histórica de 24 meses asociada a la propia prueba; SARIMAX utiliza 23 observaciones alineadas. Los modelos no aprovechan la historia de igual manera.

Las métricas comparan procedimientos completos con presupuestos de información distintos. No se puede atribuir una eventual ventaja exclusivamente a la arquitectura. La solución es explicitar esta distinción y efectuar experimentos con orígenes y cobertura histórica equivalentes.

7.3. Dos experimentos complementarios

- Historia disponible común: SARIMA/SARIMAX estimados con toda la historia hasta cada fecha; redes entrenadas en las ventanas supervisadas construibles con esa misma historia.
- Historia restringida: condiciones controladas de información limitada para comparar robustez de arquitecturas cuando escasean observaciones.

7.4. Validación anidada

Si se ajustan variables, longitudes de ventana, épocas u órdenes a partir de los mismos 24 errores externos, la evaluación deja de ser completamente independiente. Se recomienda un ciclo interno temporal de selección y un ciclo externo temporal para evaluar únicamente las especificaciones elegidas.

8. Resultados conservados en el notebook

Modelo	MAE	RMSE	MAPE	Parámetros
SARIMAX	3,5603	4,4673	5,1101 %	10
SARIMA	3,7564	5,1848	5,3474 %	4
CNN-1D	4,2102	5,9416	6,0338 %	257
TCN	4,7402	5,9306	6,7870 %	601

Fuente: salidas guardadas en el notebook. No recalculadas con la versión actual de Input_series.xlsx.

En esta ejecución, SARIMAX obtiene el menor MAE, RMSE y MAPE. SARIMA aparece en segundo lugar en las tres métricas. La CNN-1D supera a TCN en MAE y MAPE, aunque TCN registra un RMSE apenas menor que CNN-1D.

Los resultados apoyan la hipótesis de que estructuras más parsimoniosas pueden funcionar mejor con pocos datos, pero no constituyen evidencia concluyente de superioridad general de SARIMAX. Las diferencias pueden depender de la selección de meses, las configuraciones y la estrategia de estimación.

8.1. Significancia y estabilidad

El código no incorpora pruebas formales de diferencias de capacidad predictiva. Conviene comparar pérdidas pareadas por origen, estudiar diferencias temporales y considerar un contraste de Diebold–Mariano con cautela por el tamaño muestral y la dependencia entre errores. El remuestreo por bloques puede complementar el análisis.

8.2. Métricas adicionales

Además de MAE, RMSE y MAPE se sugiere evaluar sesgo medio, MASE o errores relativos a un pronóstico ingenuo estacional, desempeño por subperíodo e intervalos de predicción. MAPE debe interpretarse cuidadosamente cuando los valores de referencia se aproximan a cero.

9. Riesgo de sobreajuste y complejidad

La ejecución muestra que los dos modelos con menos parámetros también presentan menores errores promedio. Esto es compatible con insuficiencia de observaciones efectivas para las arquitecturas profundas. Sin embargo, el conteo de parámetros no es una medida de complejidad directamente homogénea entre modelos estadísticos y redes con pesos compartidos.

Es preciso diferenciar la capacidad teórica de representación de un modelo de su capacidad práctica para aprender regularidades estables a partir de datos observados. Para esta base, aumentar la complejidad sin ampliar la historia y mejorar la validación probablemente tendría retornos limitados.

10. Disponibilidad operativa y sesgo de anticipación

Usar X(t−1) en un pronóstico para t puede parecer seguro cronológicamente, pero no lo es necesariamente si la estadística correspondiente se publica con semanas o meses de demora. Debe distinguirse entre fecha del período observado y fecha en que el dato estuvo efectivamente disponible.

Se recomienda crear un calendario de publicación por indicador y emular en cada origen de pronóstico el conjunto de datos realmente conocido en esa fecha. Las revisiones posteriores de series económicas también deben documentarse; cuando sea viable, usar versiones históricas o “vintages” de los datos.

11. Matriz de riesgos metodológicos

Aspecto	Prioridad	Impacto
Datos adjuntos vs. ejecución guardada	Crítica	No se reproducen directamente las métricas informadas
Filtro de variables no seleccionadas	Alta	Descarte innecesario de observaciones
36 ejemplos supervisados	Alta	Poca información para estimar redes
SARIMA/SARIMAX con historia de 24/23 meses	Alta	Posible inestabilidad de estimación
Uso de historias distintas	Alta	Comparabilidad limitada
Sin validación interna	Alta	Riesgo de elegir hiperparámetros con información de prueba
Early stopping sobre entrenamiento	Alta	No controla generalización
Rezagos de publicación no auditados	Alta	Posible sesgo de anticipación
Saltos aleatorios entre ventanas	Media-alta	Pérdida y selección de información
Órdenes predefinidos	Media-alta	Posible especificación subóptima
Sin intervalos de predicción	Media	Incertidumbre no cuantificada
Sin contraste entre errores	Media	Robustez estadística no evaluada

12. Propuesta de rediseño metodológico

Etapa 1. Auditoría y preparación de datos

Normalizar fechas, cuantificar faltantes por serie, documentar cambios de definición, asegurar compatibilidad de unidades, verificar disponibilidad y versiones de datos y fijar un corte temporal reproducible.

Etapa 2. Exploración y selección de variables

Examinar tendencias, estacionalidad, correlaciones rezagadas, redundancias y cambios estructurales. Probar conjuntos de variables mediante validación interna sin usar el período final para decidir qué indicadores incorporar.

Etapa 3. Generación de muestras

Construir todas las ventanas mensuales consecutivas válidas para cada especificación. Comparar tamaños de ventana 12, 24, 36 y 48; asegurar que cada predictor estuviera publicado en su fecha de uso. Aplicar cualquier imputación solamente con información previa.

Etapa 4. Estimación y puntos de referencia

Mantener SARIMA, SARIMAX, CNN-1D y TCN, pero incluir un modelo ingenuo y uno ingenuo estacional; comparar la optimización temporal de órdenes, predictores, rezagos, regularización, tamaño de red y épocas. El pronóstico ingenuo es $\hat{y}(t+1)=y(t)$ y el estacional mensual es $\hat{y}(t+1)=y(t-11)$.

Etapa 5. Backtesting operativo

En cada origen, reconstruir información publicada, entrenar o actualizar, guardar predicción antes de observar el resultado, avanzar un mes y repetir. Evaluar errores pareados, sesgo, desempeño por etapa económica, sensibilidad a hiperparámetros e incertidumbre.

Etapa 6. Selección e implementación

Elegir la estrategia final combinando precisión, estabilidad temporal, disponibilidad real de datos, coste de actualización, interpretabilidad y calidad de intervalos predictivos. Documentar el procedimiento de reentrenamiento y un esquema periódico de monitoreo.

13. Cambios sugeridos al notebook

Componente actual	Cambio recomendado
Fechas numéricas	Convertir a fechas mensuales reales y validar continuidad
Selección manual de variables	Definir experimentos y selección dentro de validación interna
Saltos aleatorios de 2 o 3 meses	Usar como referencia ventanas consecutivas
Filtrado por 8 variables	Filtrar según variables usadas en cada modelo
Ventana fija de 24 meses	Comparar ventanas alternativas
SARIMA/SARIMAX con pocas observaciones	Incluir historia expansiva y optimización de órdenes
CNN/TCN con configuración fija	Optimizar capacidad, regularización y entrenamiento
Early stopping con train_loss	Utilizar pérdida de validación interna temporal
24 pruebas externas	Ampliar backtesting cuando la base lo permita
Solo métricas agregadas	Guardar errores, fechas, pronósticos, sesgo e intervalos
Archivos intermedios externos	Registrar artefactos, configuración y versión de datos

El notebook genera o utiliza, entre otros, muestras_entrenamiento.xlsx, outputs_entrenamiento.xlsx y comparacion_modelos_temporal_loo.xlsx. Contar con esos artefactos intermedios permitiría auditar las observaciones seleccionadas y los errores individuales, pero no formaron parte de los dos archivos adjuntos.

14. Conclusiones y dictamen

Conclusión 1. Pertinencia conceptual

La comparación de modelos econométricos y redes convolucionales para ventas de supermercados es pertinente. Las ventanas históricas y la validación temporal constituyen una base experimental útil.

Conclusión 2. Limitación del diseño

El principal obstáculo no es necesariamente la elección del algoritmo, sino la escasez de muestras efectivas y la falta de homogeneidad y validación independiente en el diseño de la comparación.

Conclusión 3. Desempeño observado

SARIMAX es el candidato más prometedor en la ejecución almacenada: obtiene menores MAE, RMSE y MAPE. Ello no demuestra por sí solo superioridad general ni estadísticamente significativa.

Conclusión 4. Aprovechamiento de información

La retención de solo 36 muestras supervisadas indica margen para revisar filtros, selección de variables y construcción de ventanas antes de ampliar las redes neuronales.

Conclusión 5. Reproducibilidad

Debe resolverse la inconsistencia entre planilla y resultados guardados. Una comparación no reproducible no debería utilizarse todavía como fundamento exclusivo de una decisión operativa.

Dictamen final

El desarrollo constituye una base experimental válida, pero requiere ajustes relevantes para convertir sus resultados exploratorios en conclusiones predictivas robustas y reproducibles. La prioridad es depurar los datos, reconstruir todas las ventanas factibles, emular la disponibilidad real de los indicadores, comparar estrategias con cobertura histórica documentada e implementar validación temporal anidada.

Una segunda versión del experimento debería conservar las cuatro familias de modelos y agregar puntos de referencia simples. La principal oportunidad de mejora parece residir en el diseño de los datos y del backtesting, antes que en aumentar la complejidad de las redes.

Informe preparado sobre la base del notebook, la planilla de entrada y sus resultados almacenados. No constituye certificación de reproducibilidad ni validación de un nuevo entrenamiento.